

به نام خدا

تمرین دوم درس مبانی داده کاوی

( توضیحات کارهای انجام شده )

جناب استاد دکتر قاسمی

تهیه کننده

امیرعلی خانه عنقا

**220797044**

**1401 – 1400**

## ● مقدمه

استخراج جریان می تواند به عنوان فرآیند یافتن ساختار پیچیده در یک حجم بزرگ از داده ها تعریف شود که در آن داده ها در طول زمان تکامل می یابند و به یک جریان نامحدود می رسند. جریان داده یک توالی از داده های پیوسته ورودی است که یک محدودیت یک طرفه را تحمیل می کند که در آن دسترسی تصادفی به داده ها امکان پذیر نیست.

خوشه بندی، فرآیندی است که به کمک آن می توان مجموعه ای از اشیاء را به گروه های مجزا افراز کرد. هر افراز یک خوشه نامیده می شود. اعضاء هر خوشه با توجه به ویژگی هایی که دارند به یکدیگر بسیار شبیه هستند و در عوض میزان شباهت بین خوشه ها کمترین مقدار است. در چنین حالتی هدف از خوشه بندی، نسبت دادن برچسب هایی به اشیاء است که نشان دهنده عضویت هر شیء به خوشه است.

در مقاله داده شده یک الگوریتم خوشه بندی جریان داده، به نام چگالی خود سازماندهی مبتنی بر خوشه بندی بر روی جریان داده (SOSTream) پیشنهاد شده است. این الگوریتم چندین ویژگی جدید دارد. به جای استفاده از یک آستانه تشابه تعریف شده توسط کاربر یا یک شبکه ثابت، SOSTream ساختار در جریان داده های در حال تکامل سریع را با تطبیق خودکار آستانه برای خوشه بندی مبتنی بر تراکم تشخیص می دهد.

الگوریتم های خوشه بندی جریان برای گروه بندی رویدادها براساس شباهت بین ویژگی ها مورد استفاده قرار می گیرند. داده هایی که به جریان ها می رسند اغلب حاوی نویز و داده های نامرتبط هستند. بنابراین، خوشه بندی جریان داده باید قادر به شناسایی، تشخیص و فیلتر کردن این داده ها قبل از خوشه بندی باشد.

## • خوشه‌بندی بر مبنای چگالی (Density-Bases Clustering)

روش‌های خوشه‌بندی تفکیکی قادر به تشخیص خوشه‌هایی کروی شکل هستند. به این معنی که برای تشخیص خوشه‌ها از مجموعه داده‌هایی به شکل‌های <<کوژ (Convex)>> یا محدب خوب عمل می‌کنند. در عوض برای تشخیص خوشه‌ها برای مجموعه داده‌های <<کاو>> (Concave) یا مقعر دچار خطا می‌شوند. به تصویر 1 توجه کنید که بیانگر شکل‌های کاو است.



تصویر 1: مقایسه خوشه‌بندی بر مبنای چگالی و بر مبنای تفکیکی

در الگوریتم DBSCAN دو پارامتر وجود دارد. یکی از آن‌ها شعاع است که به آن **Epsilon** نیز می‌گویند و دومی حداقل نقاط موجود در یک خوشه است که به آن **MinPoints** می‌گویند. نحوه‌ی کار الگوریتم ساده است. این الگوریتم ابتدا یک نمونه (که همان یک نقطه در فضای برداری می‌شود) را انتخاب می‌کند و با توجه به شعاع **Epsilon** به دنبال همسایه برای این نقطه در فضا می‌گردد. اگر الگوریتم در آن شعاع مشخص **Epsilon** حداقل توانست به تعداد **MinPoint** نقطه پیدا کند، آن‌گاه همه‌ی آن نقطه‌ها با هم به یک خوشه تعلق می‌گیرند. الگوریتم سپس به دنبال یکی از نقطه‌های همجوار نقطه فعلی می‌رود تا دوباره با شعاع **Epsilon** در آن نقطه به دنبال نقاط همسایه دیگر بگردد و اگر تعداد نقاط همسایه‌ی جدید باز هم پیدا شوند، این الگوریتم دوباره همه آن نقاط جدید را با نقاط قبلی به یک خوشه متعلق می‌کند و اگر نقطه‌ی جدیدی در همسایگی پیدا نکرد این خوشه تمام شده است و برای پیدا کردن خوشه‌های دیگر در نقاط دیگر، به صورت تصادفی یک نقطه دیگر را انتخاب کرده و شروع به یافتن همسایه و تشکیل خوشه‌ی جدید برای آن نقطه می‌کند. این کار آنقدر ادامه پیدا می‌کند تا تمامی نقاط بررسی شوند.

**SOSTream** یک الگوریتم خوشه‌بندی مبتنی بر چگالی است که می‌تواند آستانه خود را با جریان داده تطبیق دهد. این روش از یک تابع محوشدگی نمایی برای کاهش تاثیر داده‌های

قدیمی استفاده می کند که ارتباط آن ها در طول زمان کاهش می یابد. **SOSTream** ویژگی های جدید زیر را دارد:

- تنظیم یک آستانه به صورت دستی برای خوشه بندی مبتنی بر چگالی (آستانه تشابه، اندازه شبکه و غیره) دشوار است و اگر این پارامتر بر روی یک مقدار نامناسب تنظیم شود، آنگاه الگوریتم از بیش برآزش رنج می برد، در حالی که در نهایت خوشه بندی ناپایدار است. **SOSTream** این مساله را با استفاده از یک مقدار آستانه یادگیری پویا برای هر خوشه براساس ایده ساخت فضاهایی با حداقل تعداد نقاط، مورد بررسی قرار می دهد.

- **SOSTream** از یک استراتژی به روزرسانی خوشه ای جدید استفاده می کند که از تکنیک های یادگیری رقابتی که برای خود سازماندهی نقشه ها (**SOM** ها) و آینده (خوشه بندی با استفاده از نمایندگان) توسعه داده شده اند، الهام گرفته شده است. در آینده از یک استراتژی کوچک کردن منحصر به فرد استفاده می شود که ما را تشویق به پیاده سازی روش مشابه برای **SOSTream** می کند. خوشه های کوچکی که پس از کوچک شدن شکل می گیرند، به عنوان نماینده خوشه جهانی مورد استفاده قرار می گیرند. روند کوچک کردن همچنین به شناسایی درست خوشه های دارای همپوشانی بالا کمک می کند. در نتیجه، خوشه ها نسبت به داده های نامربوط کم تر حساس می شوند.

- تمام جنبه های **SOSTream** (از جمله حذف، اضافه کردن، ادغام و محوشدگی خوشه ها) به صورت لحظه ای انجام می شوند.

در پیاده سازی داده شده الگوریتم ها و چگونگی پیاده سازی **SOSTream** به صورت کامل قابل مشاهده است.

## خروجی های کد براساس دو دیتاست داده شده :

